

UNIVERSIDADE FEDERAL DO RIO DE JANEIRO (UFRJ)
CENTRO DE CIÊNCIAS JURÍDICAS E ECONÔMICAS (CCJE)
FACULDADE DE ADMINISTRAÇÃO E CIÊNCIAS CONTÁBEIS (FACC)
CURSO DE BIBLIOTECONOMIA E GESTÃO DE UNIDADES DE INFORMAÇÃO
(CBG)

ISABELLA OLIVEIRA DE FRANÇA

DEEP LEARNING: A RELAÇÃO ENTRE INTELIGÊNCIA ARTIFICIAL E
ORGANIZAÇÃO DA INFORMAÇÃO

Rio de Janeiro

2022

ISABELLA OLIVEIRA DE FRANÇA

**DEEP LEARNING: A RELAÇÃO ENTRE INTELIGÊNCIA ARTIFICIAL E
ORGANIZAÇÃO DA INFORMAÇÃO**

Trabalho de Conclusão de Curso
apresentado ao Curso de Biblioteconomia
e Gestão de Unidades de Informação da
Universidade Federal do Rio de Janeiro,
como requisito parcial à obtenção do título
de bacharel em Biblioteconomia e Gestão
de Unidades de Informação.

Orientador: Prof. Dr. Danilo Pestana de Freitas

Rio de Janeiro

2022

Ficha catalográfica

F814d França, Isabella Oliveira de
 Deep Learning / Isabella Oliveira de França. -- Rio de
 Janeiro, 2022.
 51 f.

 Orientador: Danilo Pestana de Freitas. Trabalho de
conclusão de curso (graduação) - Universidade Federal
do Rio de Janeiro, Faculdade de Administração e Ciências
Contábeis, Bacharel em Biblioteconomia e Gestão de
Unidades de Informação, 2022.

 1. Deep learning. 2. Inteligência artificial. 3. Organização
da informação. 4. Internet das coisas. I. Freitas, Danilo
Pestana de, orient. II. Título.

ISABELLA OLIVEIRA DE FRANÇA

**DEEP LEARNING: A RELAÇÃO ENTRE INTELIGÊNCIA ARTIFICIAL E
ORGANIZAÇÃO DA INFORMAÇÃO**

Trabalho de Conclusão de Curso
apresentado ao Curso de Biblioteconomia
e Gestão de Unidades de Informação da
Universidade Federal do Rio de Janeiro,
como requisito parcial à obtenção do título
de bacharel em Biblioteconomia e Gestão
de Unidades de Informação.

Rio de Janeiro, 17 de fevereiro de 2022.

Prof. Dr. Danilo Pestana de Freitas
Orientador

Prof. Dra. Ana Maria Ferreira De Carvalho
Membro interno

Prof. Ma. Carla Beatriz Marques Felipe
Membro interno

Dedico este trabalho aos meus queridos pais.

AGRADECIMENTOS

A execução deste trabalho contou com a colaboração de pessoas muito importantes na minha jornada acadêmica, profissional e pessoal, dentre as quais agradeço:

A minha família, especialmente meus pais, por ter sido meu suporte emocional e apoio essencial em cada etapa do processo. Obrigada por terem acreditado tanto em mim e no meu potencial. Vocês sempre serão a razão de todas as minhas conquistas. A vocês, todo meu amor.

Ao meu orientador Prof. Dr. Danilo Pestana de Freitas pelo incansável esforço, dedicação e compreensão para que esse estudo ganhasse vida.

A todo corpo docente e discente do curso de Biblioteconomia e Gestão de Unidades de Informação da UFRJ por tamanha troca de conhecimento nesses últimos anos. Levarei todos os ensinamentos pelo resto da minha vida.

A minha madrinha, que é uma figura essencial e inspiradora para o meu desenvolvimento educacional e pessoal. Obrigada por ter me ensinado tanto sobre a vida e por ser uma fonte de amor incondicional.

As minhas afilhadas, Anna e Sophia, que me enchem de felicidade e momentos bons que sempre carrego comigo.

E, por fim, aos meus amigos por entenderem minha ausência em diversas ocasiões sociais, e por sempre me fornecerem apoio, sorrisos, conselhos e acolhimento quando preciso.

*“O cérebro—é mais vasto que o céu—
Pois—se colocarmos lado a lado—
Aquele o outro contém
Facilmente—e a você—também—”*

(DICKINSON, 1863)

RESUMO

A inteligência artificial se tornou uma das inovações indispensáveis nas empresas e na rotina da sociedade por ser responsável pela automatização de tarefas, antes desenvolvidas por humanos, de forma eficaz e eficiente. Nesse sentido, o Deep Learning, ou aprendizagem profunda, é uma aplicação dentro do campo de aprendizagem de características, que consiste em camadas de processamento, chamadas redes neurais, que buscam possuir uma dinâmica semelhante à dos neurônios do cérebro humano. Através da ordenação de dados para processamento, as camadas de redes neurais interagem e desenvolvem uma análise metódica baseando-se nos parâmetros estipulados. Neste trabalho, o objetivo foi explorar e analisar teoricamente como funcionam as aplicações de Deep Learning e o papel da organização da informação nas redes neurais, além da avaliação sobre o uso de dispositivos e serviços dessa natureza. Para tanto, a pesquisa foi fundamentada a partir de estudos bibliográficos, e da análise de dados obtidos através da aplicação de um questionário quantitativo e qualitativo. Dessa maneira, espera-se que o estudo contribua para fomentar a familiarização de profissionais da informação com tecnologias predominantes e expansíveis. Em adição, propor melhorias relacionadas ao uso de dispositivos e serviços inteligentes já existentes.

Palavras-chave: deep learning; inteligência artificial; organização da informação; internet das coisas.

ABSTRACT

Artificial intelligence has become one of the crucial innovations in companies and everyday life in society, because it is responsible for tasks automation, previously done manually by humans, effectively and efficiently. In this perspective, Deep Learning is an application within the field of feature learning, which consists of processing layers, called neural networks, which seek to have a similar dynamic to neurons of the human brain. Through the ordering of data for processing, the layers of neural networks interact and develop a meticulous analysis based on specified parameters. In this research, the objective is to explore and theoretically analyze how Deep Learning applications work and the role of knowledge organization in neural networks, in addition to evaluating the use of devices and services of this nature. Therefore, the research will be based on bibliographic studies and the analysis of data obtained through the application of a quantitative and qualitative survey. For this reason, the research is expected to contribute to information professionals becoming more familiar with predominant and expandable technologies. Furthermore, suggest improvements related to the use of existing smart devices and services.

Keywords: deep learning; artificial intelligence; knowledge organization; internet of things.

LISTA DE ILUSTRAÇÕES

Figura 1 –	Campos da Inteligência Artificial.....	17
Figura 2 –	Redes neurais backpropagation e feedforward.....	20
Gráfico 1 –	Curso da graduação.....	35
Gráfico 2 –	Áreas de domínio de conhecimento.....	36
Gráfico 3 –	Ordenação de dados e informações na rotina.....	37
Gráfico 4 –	Uso de serviços e dispositivos.....	38
Gráfico 5 –	Sincronização dos serviços e dispositivos.....	40
Gráfico 6 –	Compreensão da dinâmica do fluxo informacional em Deep Learning.....	41
Gráfico 7 –	Problemas com o uso de serviços ou dispositivos	42

SUMÁRIO

1	INTRODUÇÃO	10
1.1	PROBLEMA.....	11
1.2	OBJETIVOS.....	11
1.2.1	Objetivo geral	11
1.2.2	Objetivo específico	11
1.3	JUSTIFICATIVA.....	12
2	REFERENCIAL TEÓRICO	13
2.1	INTELIGÊNCIA ARTIFICIAL.....	13
2.1.1	Machine learning	14
2.1.1.1	Deep learning.....	16
2.2	INTERNET DAS COISAS.....	24
2.3	ORGANIZAÇÃO DA INFORMAÇÃO.....	26
2.4	GESTÃO DA INFORMAÇÃO.....	30
3	PROCEDIMENTOS METODOLÓGICOS	32
3.1	CAMPO DA PESQUISA, POPULAÇÃO E AMOSTRA.....	32
3.2	TÉCNICAS DE COLETA E ANÁLISE DE DADOS.....	33
4	RESULTADOS	34
5	CONCLUSÃO	44
	REFERÊNCIAS	46
	APÊNDICE A – MODELO DO QUESTIONÁRIO	48

1 INTRODUÇÃO

Com demandas sociais de praticidade e o desenvolvimento contínuo de novas formas tecnológicas de automatização de diversos processos, a inteligência artificial se torna cada vez mais onipresente na rotina da sociedade. Desde serviços simples até automóveis de condução autônoma, o campo de estudo em questão mostra-se de grande complexidade quando explorado desde sua configuração informacional até a ação já processada direcionada ao usuário.

Nessa perspectiva, o papel desempenhado pela organização da informação em estruturas de deep learning, aplicação que segundo Goodfellow, Bengio e Courville (2016) está inserida no campo da inteligência artificial, especificamente em aprendizagem de características, é essencial na dinâmica de ensinamento e processamento de máquinas.

Esta complexa arquitetura, formada por camadas de redes neurais, atraiu ainda mais a atenção de profissionais da tecnologia a processos e sistemas de organização da informação. Com isso, além da eficiência na automatização de diversos processos que antes eram manuais, aplicações Deep Learning desempenham papel crucial e de popularmente crescente na disciplina de internet das coisas (LIN, 2020).

Dito isso, o deep learning é o método de automação que mais desperta interesse atualmente por parte de indivíduos e empresas. O sistema é responsável por permitir a identificação de imagens, reconhecimento de falas, transcrição de textos, entre outros (LECUN; BENGIO; HINTON, 2015).

A atenção recebida pela tecnologia não é somente pelas inovadoras redes neurais estruturadas e portadoras dos dados que são responsáveis pela autonomia da máquina, mas, principalmente, por ser a aplicação que mais se aproxima do funcionamento do cérebro humano e da cognição natural desenvolvida até o atual momento (GOODFELLOW; BENGIO; COURVILLE, 2016).

Máquinas de aprendizagem autônoma e o campo da organização de informação se conectam pela necessidade de sistemas e processos para tratar as informações obtidas a partir de dados, consequentemente permitindo à máquina entregar a tarefa programada pelo modelo algoritmo com eficiência e menor índice

de chance de erro. Dito isso, o estudo e a análise da organização dentro de sistemas tecnológicos são necessários para a maior compreensão, melhorias e solução de possíveis problemas.

1.1 PROBLEMA

Considerando a importância da organização da informação em aplicações Deep Learning para processar e sistematizar características e informações, se deseja investigar como dispositivos e serviços de deep learning podem afetar a rotina dos usuários ao apresentarem problemas relacionados ao fluxo informacional.

1.2 OBJETIVOS

1.2.1 Objetivo geral

O principal objetivo da pesquisa é analisar a relação entre deep learning e organização da informação.

1.2.2 Objetivos específicos

- a) Apresentar os principais conceitos sobre deep learning e organização da informação;
- b) Apresentar a internet das coisas e correlacionar com deep learning;
- c) Analisar a relação da disposição e classificação da informação no funcionamento das redes neurais que compõem as camadas do deep learning;
- d) Realizar pesquisa de campo com estudantes de Biblioteconomia e Ciência da Computação sobre a presença de dispositivos e serviços que utilizam deep learning na rotina, e os problemas percebidos durante o uso.

1.3 JUSTIFICATIVA

Mesmo sendo um dos campos da tecnologia que está presente com maior frequência na rotina da sociedade, a comunicação e conexão entre as áreas da ciência da informação e ciência da computação é pouco explorada cientificamente e academicamente, tornando-se ainda mais incomum quando limitado à língua portuguesa.

Além disso, a escolha do tema para o trabalho é atribuída, principalmente, pela consciência da importância, e impacto dos processos e sistemas organizacionais em grandes estruturas tecnológicas inteligentes de deep learning, que atualmente exercem grande influência sobre o comportamento da sociedade e se tornaram protagonistas responsáveis por desempenhar atividades automatizadas em diferentes circunstâncias presentes na rotina.

2 REFERENCIAL TEÓRICO

2.1 INTELIGÊNCIA ARTIFICIAL

A inteligência artificial é o campo de estudo em que é planejada e desenvolvida a simulação mais próxima da inteligência humana em máquinas com o objetivo de replicar ações que seriam executadas por indivíduos em computadores de modo automático e eficiente (GOODFELLOW; BENGIO; COURVILLE, 2016).

Como é considerada a reprodução de humanização na tecnologia, o avanço progressivo do desenvolvimento da inteligência artificial instaurou debates sociais variados em relação aos limites da automatização do imaterial.

Para Gottfredson (1997, apud JESTE et al., 2020), não é possível encontrar uma única definição para inteligência. Porém, é dito que especialistas acreditam que a essência da inteligência é a capacidade mental que envolve a habilidade raciocinar, planejar, resolver problemas, pensar abstratamente, compreender ideias complexas, aprender rapidamente e com experiência.

Nesse sentido, Jeste et al. (2020) acrescenta que existem diversas teorias sobre a conceituação de inteligência. Embora sejam ligeiramente diferentes, a maioria das teorias concordam que a inteligência é uma construção multifatorial composta por vários componentes e integra uma série de domínios e habilidades cognitivas, particularmente o processamento sensorial, como atenção e memória de trabalho. Além de: linguagem, conhecimento adquirido, consolidação e recuperação de memória, processamento e velocidade psicomotora e raciocínio.

Apenas os seres humanos podem possuir as características necessárias para desenvolver e cultivar a sabedoria. Ademais, a sociedade possui influência nos elementos que fazem parte do processo de cognição. Contudo, humanos podem desenvolver computadores para operacionalmente realizar ações que utilizam princípios ou resultados cognitivos (SEVILLA, 2013 apud JESTE et al., 2020).

Complementando o que foi previamente dito pela autora citada, Jeste et al. (2020), apesar de todo o avanço feito no campo da tecnologia, somente a inteligência não é suficiente para o desenvolvimento de um raciocínio cognitivo em máquinas. Um sistema sábio aprenderá com a experiência, integrará múltiplas

perspectivas, bem como cenários anteriores para tomar decisões e ações baseadas nessas informações. "As tecnologias de IA do futuro exigirão novos modelos conceituais e computacionais baseados na sabedoria humana e não na inteligência humana, para produzir um conhecimento artificial." (JESTE et al., 2020, p. 999).

2.1.1 Machine learning

O aprendizado de máquina, ou machine learning, é um método que consiste em treinar máquinas através de dados e algoritmos inseridos de forma manual por desenvolvedores para reproduzirem determinados padrões de ações de forma autônoma, a partir de modelos transcritos de dados previamente analisados e estruturados (GOODFELLOW; BENGIO; COURVILLE, 2016).

Conforme descrito por esses autores, é um processo desafiador encaixar os dados responsáveis pelo ensinamento da máquina, assim como encontrar padrões para gerar mais dados e ambos são processos diferentes. E os algoritmos que constituem o machine learning têm configurações chamadas hiper parâmetros que devem ser determinados externamente ao próprio algoritmo responsável por ensinar a máquina. O aprendizado de máquina é uma forma de estatística aplicada com maior foco no uso de computadores para estimar estatisticamente funções complexas e menor em provar intervalos de confiança em torno dessas funções. Os algoritmos podem ser divididos em classificações de educação supervisionada e educação não supervisionada. "Por exemplo, se quisermos que um robô seja capaz de andar, a tarefa é andar. Podemos programar o robô para aprender a andar, ou podemos tentar escrever diretamente um programa que especifica como andar manualmente." (GOODFELLOW; BENGIO; COURVILLE, 2016, p. 99).

Nesse sentido, os algoritmos destinados à aprendizagem são capazes de compreender a partir de dados. Dito isso, esse tipo de algoritmo possibilita que a máquina lide com tarefas que são muito complexas de resolver com planos fixos, escritos e projetados por seres humanos. O aprendizado é como a máquina consegue realizar a tarefa que foi designada (GOODFELLOW; BENGIO; COURVILLE, 2016).

Um programa de computador é ensinado a aprender com a experiência "E" no que diz respeito a alguma classe de tarefas "T" e medição de desempenho "P", se o seu desempenho nas tarefas em "T", conforme medido por "P", melhora com a experiência "E". (MITCHELL, 1997 apud GOODFELLOW; BENGIO; COURVILLE, 2016, p. 99).

As tarefas desempenhadas por essas máquinas são descritas como a forma de uma máquina de processar um exemplo, que é uma coleção de características que foram medidas para serem computadas. Nesse sentido, algumas das tarefas mais comuns de machine learning são: classificação (completa ou com falhas de entrada), regressão, transcrição, tradução da máquina, detecção de anomalias e densidade estimada. Todas realizadas por algoritmos destinados ao aprendizado de máquina.

Nesse sentido, esse algoritmo é avaliado quanto ao seu desempenho através de uma medida quantitativa obtida através da performance e essa medida costuma ser particular a uma tarefa desempenhada. Ou seja, na maioria das vezes, cada tarefa possui uma medição específica e adequada para avaliar o desempenho durante o processo.

Segundo Goodfellow, Bengio e Courville (2016), existe maior interesse no desempenho do algoritmo de aprendizado de máquina em dados que não viu antes. Portanto, avaliamos essas medidas de desempenho usando um conjunto de dados de teste separado dos dados usados para treinar a máquina sistema de aprendizagem.

O obstáculo é a escolha da medida de desempenho que deverá ser usada. Visto que, em algumas situações pode ser difícil determinar o que deve ser medido, logo, a medição pode aparentar ser a mais adequada e não corresponder ao comportamento desejado do sistema.

Em outra direção, a experiência trata de como são os algoritmos que guiam as tarefas: supervisionados ou não-supervisionados. Como são formas distintas de processar os dados, cada um estabelece uma experiência diferente com a máquina.

Enquanto os algoritmos supervisionados se restringem ao aprendizado e processamento do que é apontado como um ponto de relevância para determinada tarefa por quem o programou, os algoritmos não-supervisionados analisam

exemplos de uma grande quantidade de dados e, a partir disso, desenvolvem um aprendizado baseado nas características úteis do objeto de análise.


Aprendizado de máquina é essencialmente uma forma de estatística aplicada com maior ênfase no uso de computadores para estimar estatisticamente funções complicadas e uma maior ênfase em provar intervalos de confiança em torno dessas funções. (GOODFELLOW; BENGIO; COURVILLE, 2016, p. 99)

Em outras palavras, as tecnologias que utilizam simples aplicações de machine learning podem ter a autonomia limitada dependendo da estrutura matemática com a qual a máquina funciona. Logo, nem todas as máquinas inteligentes são capazes de analisar diretamente e detalhadamente as informações que processam. Sua capacidade de processamento pode ser restrita a sua codificação e ao que está sendo indicado na mesma.

2.1.1.1 Deep learning

Sendo a aplicação mais recente e desenvolvida do campo de inteligência artificial, o deep learning consiste em redes neurais complexas que se conectam para maior compreensão ao analisar e classificar dados, se aproximando do raciocínio e da intuição humana e, com isso, diminuindo as chances de possíveis erros durante o processamento (LECUN; BENGIO; HINTON, 2015).

FIGURA 1 - CAMPOS DA INTELIGÊNCIA ARTIFICIAL



Fonte: Goodfellow, Bengio e Courville (2016)

De acordo com Lecun, Bengio e Hinton (2015), a aplicação Deep learning é o método mais eficiente já desenvolvido na área da inteligência artificial, visto que possui grande capacidade de aprendizado autônomo, o que não era possível em estudos desenvolvidos previamente, e requer pouca execução manual.

Aprendizagem de representação é um conjunto de métodos que permitem que uma máquina seja alimentada com dados brutos e descubra automaticamente as representações necessárias para detecção ou classificação. Os métodos de aprendizagem profunda são métodos de aprendizagem de representação com vários níveis de representação, obtidos pela composição de módulos simples, mas não lineares, em que cada um transforma a representação em um nível (começando com a entrada bruta) em uma representação em um nível mais alto, ligeiramente mais abstrato. Com a composição de tais transformações, funções muito complexas podem ser aprendidas (LECUN; BENGIO; HINTON, 2015, p. 436).

Neste sentido, o aprendizado é possível através de redes neurais, que são constituídas de algoritmos que permitem o processamento de dados e, por meio da orientação da arquitetura das camadas, ensinam a máquina treinada a classificar os materiais com fundamentação em uma estrutura inteligente interligada.

Segundo os autores, além das fórmulas matemáticas desenvolvidas e da arquitetura das redes, o grande número de dados que são reunidos para treinar essa máquina é essencial para o funcionamento bem-sucedido desse método. Quanto maior for a quantidade de material apresentado, maior o número de parâmetros e delimitações que a máquina consegue reconhecer e classificar em um grupo de materiais.

Para tarefas de classificação, camadas superiores de representação amplificam aspectos da entrada que são importantes para a discriminação e suprimem variações irrelevantes. Uma imagem, por exemplo, vem na forma de uma matriz de valores de pixel, e os recursos aprendidos na primeira camada de representação normalmente representam a presença ou ausência de bordas em orientações e locais específicos na imagem. A segunda camada normalmente detecta motivos identificando arranjos particulares de bordas, independentemente de pequenas variações nas posições das bordas. A terceira camada pode reunir características em combinações maiores que correspondem a partes de objetos familiares, e as camadas subsequentes detectam objetos como combinações dessas partes. O aspecto principal do aprendizado profundo é que essas camadas de recursos não são projetadas por engenheiros humanos: elas são aprendidas a partir de dados usando um procedimento de aprendizado de propósito geral. (LECUN; BENGIO; HINTON, 2015, p. 436)

De acordo com Goodfellow, Bengio e Courville (2016), o obstáculo da aprendizagem profunda é, através das complexas camadas de redes neurais que se comunicam, aproximar as habilidades da máquina do conhecimento intuitivo que os seres humanos possuem e é constituído através de experiências vividas na rotina.

Nessa perspectiva, tarefas que requerem maior raciocínio humano e conseguem ser transcritas com precisão dentro de algoritmos são facilmente executadas por máquinas, apesar de serem de difícil realização para humanos. No entanto, a cognição, responsável por permitir o discernimento entre possibilidades, é subjetiva e informal.

Como é abstrata e não poderia ser facilmente expressa em algoritmos concretos, a aprendizagem profunda das máquinas e sua dinâmica de

funcionamento possui uma estrutura que permite o desenvolvimento de uma inteligência mais autônoma e com menores chances de falha que estudos previamente desenvolvidos dentro do campo de estudo da inteligência artificial.

O desempenho desses algoritmos simples de aprendizado de máquina depende muito da representação dos dados que são fornecidos. Por exemplo, quando a regressão logística é usada para recomendar parto cesáreo, o sistema de inteligência artificial não examina o paciente diretamente. Em vez disso, o médico insere no sistema várias informações relevantes, como a presença ou ausência de cicatriz uterina. Cada pedaço das informações incluídas na representação do paciente é conhecido como uma característica.

[...]

Essa dependência de representações é um fenômeno geral que aparece em toda a ciência da computação e, até mesmo, na vida cotidiana. Na ciência da computação, operações como pesquisar uma coleção de dados pode ocorrer exponencialmente mais rápido se a coleção é estruturada e indexada de forma inteligente. As pessoas podem executar facilmente aritmética em algarismos arábicos, mas encontrar aritmética em algarismos romanos é mais demorado. Não é surpreendente que a escolha da representação tenha um enorme efeito no desempenho de algoritmos de aprendizado de máquina. (GOODFELLOW; BENGIO; COURVILLE, 2016, p. 3)

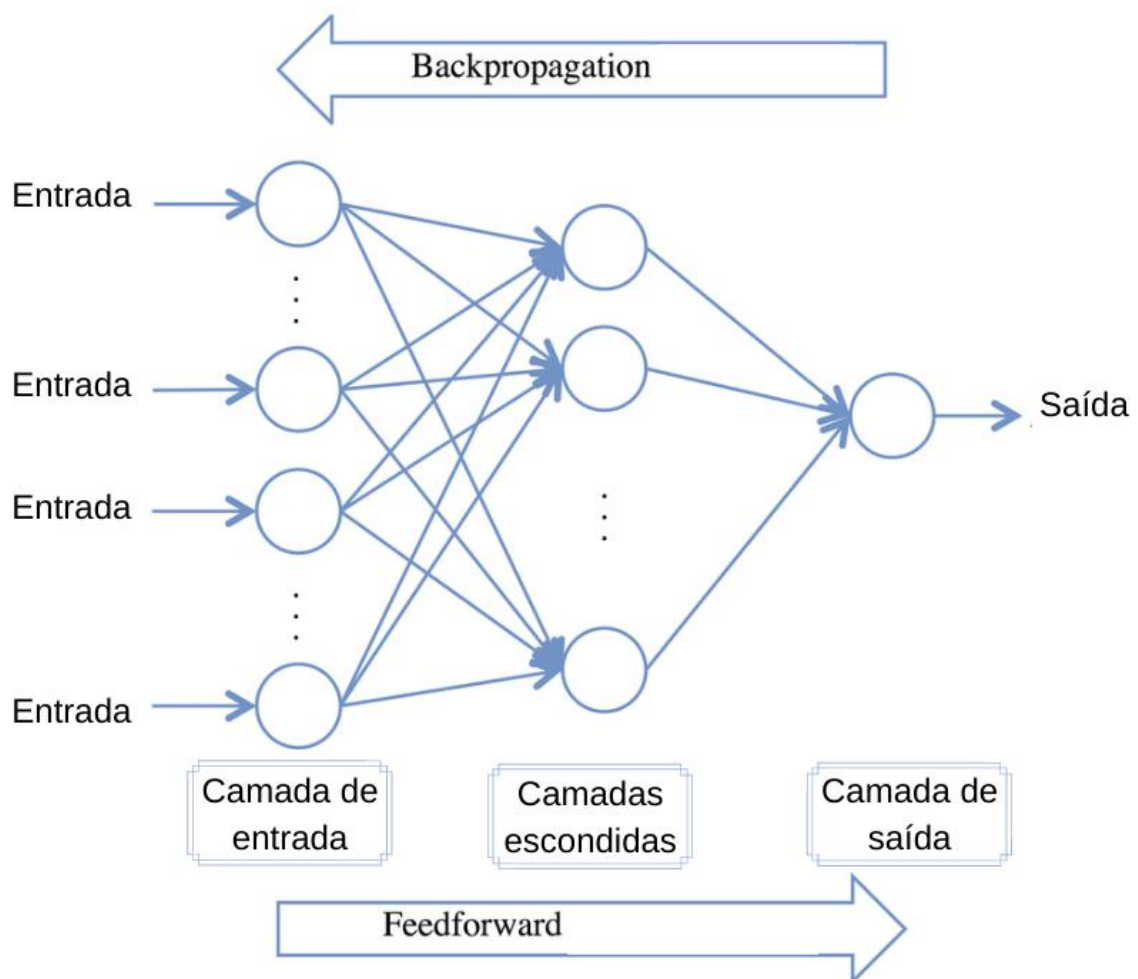
Dito isso, surgiu a necessidade do desenvolvimento de uma forma mais eficaz para o processamento de dados. A aprendizagem de representação consagrou-se como um conjunto de diferentes métodos que permitem o uso de dados brutos na máquina para que automaticamente seja entendido o que está sendo representado.

Em relação aos métodos, eles possuem diversos níveis de representação, que não funcionam de forma linear. A cada nível, a representação se torna mais complexa e detalhada. Esse processo começa sempre pelo ponto de partida do dado: em sua forma pura e inalterada, como é inserido na máquina. Em relação a isso, o aprendizado supervisionado se destaca por ser o mais usado. Nesse método, coleta-se uma quantidade significativa de dados sobre o objeto ou assunto em questão. A partir disso, a máquina produz vetores de pontuações, de acordo com cada categoria analisada. Somente com a comparação dessas pontuações e dos padrões de pontuação desejados é possível ajustar e ensinar a máquina a ser cada vez mais precisa com o processamento. Os parâmetros ajustáveis numerais são usados para reduzir erros (LECUN; BENGIO; HINTON, 2015).

Uma arquitetura de aprendizado profundo é uma pilha de multicamadas de módulos simples, todos (ou a maioria) dos quais estão sujeitos ao aprendizado e muitos dos quais calculam mapeamentos de entrada-saída não lineares. Cada módulo da pilha transforma sua entrada para aumentar a seletividade e a invariância da representação. Com várias camadas não lineares, digamos uma profundidade de 5 a 20, um sistema pode implementar funções extremamente intrincadas de suas entradas que são simultaneamente sensíveis a detalhes finos - distinguindo Samoyeds de lobos brancos - e impassível a grandes variações irrelevantes, como plano de fundo, pose, iluminação e objetos ao redor (LECUN; BENGIO; HINTON, 2015, p. 438).

Assim sendo, as camadas de redes neurais não-lineares e os conceitos que serão apresentados posteriormente se encontram ilustrados a seguir para melhor visualização de seu funcionamento (FIGURA 2).

FIGURA 2 - REDES NEURAIS BACKPROPAGATION E FEEDFORWARD



Fonte: M'NG; MEHRALIZADEH, 2016.

Nesse sentido, entende-se que o funcionamento do deep learning ocorre devido às diversas camadas de redes inteligentes que funcionam pelo modelo matemático de backpropagation. Segundo Lecun, Bengio e Hinton (2015), o backpropagation é o principal responsável por treinar a arquitetura das múltiplas camadas de uma máquina. O ponto principal do treinamento é o cálculo do gradiente, que é o mais aplicado em módulos simples e de menor complexidade. Nesse caso, é essencial que o gradiente do objetivo em relação à entrada de um módulo possa ser calculado trabalhando para trás a partir do gradiente em relação à saída desse módulo ou a entrada do módulo subsequente. Quando o gradiente é calculado, esse resultado é comparado com o peso dos módulos.

Quanto às camadas, elas são redes neurais que processam os dados dentro de um modelo que oferece autonomia à máquina de acordo com a menor chance de falhas, a partir do comparativo do gradiente citado anteriormente. De acordo com Jürgen Schmidhuber (2015), redes neurais comuns consistem em múltiplos processadores simples e conectados. Cada processador produz ativações com determinado valor e são chamados de neurônios, baseando-se em um comparativo dessa arquitetura ao funcionamento do cérebro humano.

Os neurônios de entrada são ativados por meio de sensores que percebem o ambiente, outros neurônios são ativados por meio de conexões ponderadas de neurônios previamente ativos. Alguns neurônios podem influenciar o ambiente acionando ações. Aprendizagem ou atribuição de crédito é sobre encontrar pesos que fazem a rede neural apresentar o comportamento desejado, como dirigir um carro. Dependendo do problema e de como os neurônios estão conectados, tal comportamento pode exigir longas cadeias causais de estágios computacionais, onde cada estágio transforma (frequentemente de forma não linear) a ativação agregada da rede (SCHMIDHUBER, 2015, p. 4).

Em 2006, ocorreu um marco de importância para o desenvolvimento no deep learning que é observado na rotina da sociedade atualmente. Segundo Lecun, Bengio e Hinton (2015), um grupo de pesquisadores reunidos pelo Instituto Canadense de Pesquisa Avançada (CIFAR) demonstrou interesse em explorar redes feedforward, um dos modelos estruturais de redes neurais. Foram apresentados procedimentos de aprendizagem não supervisionados que poderiam dar origem a camadas que detectariam características, sem a necessidade de dados rotulados.

Nessa perspectiva, Goodfellow, Bengio e Courville (2016) complementam que feedforward é um modelo de deep learning que funciona como um mapeamento matemático simples de valores de entrada para valores de saída.

A inovação advinda dos estudos e da aplicação dessas redes permitiu diversas ações como o reconhecimento de manuscritos, reconhecimento de fala, identificação de pedestres, entre outros. Esses avanços, que poderiam demorar um tempo muito maior para acontecerem, só foram possíveis pois as redes feedforward permitiram que os pesquisadores fossem capazes de treinar máquinas com uma velocidade até 20 vezes maior que a anterior. Dito isso, a rede feedforward predominantemente usada é a rede neural convolucional, por ser mais fácil de treinar e capaz de generalizar melhor do que redes com conectividade total entre camadas adjacentes (LECUN; BENGIO; HINTON, 2015).

Redes neurais convolucionais são projetadas para processar dados em forma de vários arrays, por exemplo, uma imagem colorida composta de três arrays 2D contendo intensidades de pixel nos três canais de cores. Muitas modalidades de dados estão na forma de vários arranjos: 1D para sinais e sequências, incluindo linguagem; 2D para imagens ou espectrogramas de áudio; e 3D para vídeo ou imagens volumétricas. Existem quatro ideias principais por trás dessas redes que tiram proveito das propriedades dos sinais naturais: conexões locais, pesos compartilhados, pooling e o uso de muitas camadas. A arquitetura típica é estruturada como uma série de estágios (LECUN; BENGIO; HINTON, 2015, p. 439).

Nessa perspectiva, essas redes neurais, que são responsáveis pela existência de carros autônomos e detecção de fala, exploram a propriedade de que muitos sinais naturais são hierarquias composicionais, nas quais os recursos de nível superior são obtidos pela composição de outros de nível inferior. Hierarquias semelhantes existem na fala e no texto, de sons a telefones, fonemas, sílabas, palavras e frases. O agrupamento permite que as representações variem muito pouco quando os elementos da camada anterior variam em posição e aparência (LECUN; BENGIO; HINTON, 2015).

A questão da representação está no cerne do debate entre os paradigmas de cognição inspirados na lógica e os inspirados nas redes neurais. No paradigma inspirado na lógica, uma instância de um símbolo é algo para o qual a única propriedade é ser idêntico ou não idêntico a outras instâncias de símbolo. Não possui estrutura interna relevante para seu uso; e para

raciocinar com símbolos, eles devem ser limitados às variáveis em regras de inferência judiciosamente escolhidas. Em contraste, as redes neurais apenas usam vetores de grande atividade, matrizes de grande peso e não linearidades escalares para realizar o tipo de inferência "intuitiva" rápida que sustenta o raciocínio comum sem esforço (LECUN; BENGIO; HINTON, 2015, p. 441).

Logo, com o desenvolvimento das redes neurais profundas, o deep learning começou a destacar-se ao apresentar benefícios em determinados tipos de processamento em relação a outras aplicações de aprendizagem e que não utilizam representações similares. Considerando os benefícios, o principal é o foco na máquina ser capaz de solucionar problemas que exigem cognição, algo que não era possível antes (GOODFELLOW; BENGIO; COURVILLE, 2016). Isso se deve à composição das redes neurais e da distribuição de diversos estímulos que permitem o processamento dentro das estruturas de camadas.

Segundo Lecun, Bengio e Hinton (2015), as representações distribuídas de aprendizagem permitem a generalização para novas combinações dos valores de recursos aprendidos, além dos que foram ensinados durante o treinamento. Ademais, as camadas ocultas de uma rede neural multicamadas aprendem a representar as entradas da rede de uma maneira que torna mais fácil prever as saídas alvo. Na primeira camada, cada palavra cria um padrão diferente de ativações, ou vetores de palavras. Dentro do modelo de linguagem, as outras camadas da rede aprendem a converter os vetores de palavras de entrada em um vetor de palavras de saída para a próxima palavra prevista, que pode ser usado para prever a probabilidade de qualquer palavra no vocabulário aparecer como a próxima palavra.

Logo, a rede aprende vetores de palavras que contêm muitos componentes ativos, cada um pode ser interpretado como um recurso separado da palavra. Esses recursos semânticos não estavam explicitamente presentes na entrada. Eles foram descobertos pelo procedimento de aprendizagem como uma boa maneira de fatorar as relações estruturadas entre os símbolos de entrada e saída em múltiplas regras (LECUN; BENGIO; HINTON, 2015).

2.2 INTERNET DAS COISAS

A novidade associada à internet das coisas (IoT) decorre de seu potencial de aplicação generalizada, visto que as barreiras técnicas associadas à vigilância automatizada estão gradualmente se desgastando, diminuindo drasticamente os custos associados em seu rastro. Os equipamentos técnicos necessários, como computadores e sensores, ficaram menores e mais eficientes. As taxas de tráfego de dados diminuíram à medida que infraestruturas de redes sem fio de alta capacidade se expandiram a uma velocidade vertiginosa. A capacidade de criar interfaces entre tipos de rede foi aprimorada, tornando possível acomodar vários padrões e formatos, além de fornecer conectividade contínua (SAARIKKO; WESTERGREN; BLOMQUIST, 2017).

A capacidade de conectar cidades inteiras e fornecer dados em tempo real fornece oportunidades para que podemos apenas começar a especular. Autoridades podem monitorar as condições de tráfego e a qualidade do ar no interesse da segurança pública. O comércio local pode ver como e quando os compradores circulam e anunciam seus bens e serviços em conformidade. Um por um, barreiras técnicas estão desmoronando. A IoT está crescendo mais madura e suas aplicações mais prolíficas. As limitações reais que permanecem são as que são mantidas firmemente no lugar por nossa falta de imaginação (SAARIKKO; WESTERGREN; BLOMQUIST, 2017, p. 669).

Na mesma perspectiva, o conceito de internet das coisas é baseado na integração de vários padrões e tecnologias habilitadas com diferentes sensores, conectividade, armazenamento e recursos computacionais. No entanto, a fragmentação de padrões e diversidades em tecnologias são obstáculos na existência de uma conectividade total, consequentemente tornando a integração um processo desafiador (ČOLAKOVIĆ; HADŽIALIĆ, 2018).

Outra definição é que a IoT é uma rede inteligente que conecta todas as coisas à internet com o objetivo de trocar informações e se comunicar com os dispositivos de detecção de informações de acordo com os protocolos acordados (Chen et al., 2014 apud ČOLAKOVIĆ; HADŽIALIĆ, 2018).

Nesse sentido, as plataformas de IoT podem ser definidas como camadas inteligentes que conectam elementos à rede e abstrai aplicações dos elementos com

o objetivo de possibilitar o desenvolvimento de serviços. Dentre as plataformas de IoT, pode-se citar hardware e plataformas em nuvem (ČOLAKOVIĆ; HADŽIALIĆ, 2018).

O número de objetos conectados aumenta, assim como os dados brutos (dados não estruturados) que precisam ser gerenciados e processados. Enormes quantidades de dados, incluindo dados em tempo real, são coletados de fontes heterogêneas, como sensores, objetos inteligentes, bem como redes sociais e a web. Dados e serviços são fragmentados em muitas entidades, incluindo armazenamento de dados e unidades de processamento. As tecnologias da web semântica, como RDF (Resource Description Framework), são desenvolvidas como um modelo para intercâmbio de dados na Web para facilitar a fusão de dados. Os formatos de mensagem podem ser classificados em baseados em texto e baseados em binários. Após a conversão dos dados em estrutura de objeto interno, ele está pronto para processamento e visualização. As codificações baseadas em texto mais usadas são XML e JSON e esses formatos fornecem dados legíveis por humanos (ČOLAKOVIĆ; HADŽIALIĆ, 2018, p. 21).

O domínio do objeto apresenta a camada de endpoint que inclui elementos físicos e elementos virtuais. Esses objetos têm vários recursos, como detecção, atuação, identificação, armazenamento e processamento de dados, conexão com outros objetos e integração em redes de comunicação. Os objetos IoT incluem softwares incorporados e hardware. Sensores são objetos que detectam e medem alguma mudança no ambiente, como temperatura, pressão do ar, aceleração, luz, movimento, entre outros. Eles executam várias ações para fornecer uma saída para processamento futuro. Vários sensores são incorporados em muitos objetos, como celulares, para permitir serviços de valor agregado com base na IoT (ČOLAKOVIĆ; HADŽIALIĆ, 2018).

Em outro sentido, Lin (2020) adverte para os riscos a serem considerados em relação a deep learning na internet das coisas. A popularidade das aplicações de redes neurais cresce cada vez mais na rotina social e nos campos científicos. Cita-se como ponto de atenção o desempenho da precisão de deep learning em questões de segurança, como identificação de malwares. Enquanto deep learning é eficaz em casos não tão complexos, como a classificação de animais, achar uma abordagem adequada para tratar de assuntos de segurança é desafiador. De acordo

com o autor, a percepção e a precisão não coexistem em diversos sistemas deep learning.

A padronização de estruturas tecnológicas é considerada como a base para o desenvolvimento e implantação da IoT no futuro. Diversos padrões estão sendo desenvolvidos, aprovados e mantidos por um processo de tomada de decisão baseado em consenso colaborativo para fornecer melhor interoperabilidade para sistemas que usam tecnologias diferentes. Ademais, ao usar padrões abertos, há menor possibilidade de limitação a um único fornecedor ou tecnologia específica, o que é benéfico para o desenvolvimento da IoT (ČOLAKOVIĆ; HADŽIALIĆ, 2018).

2.3 ORGANIZAÇÃO DA INFORMAÇÃO

Segundo Le Coadic (2004 apud LIMA; ALVARES, 2012), dados são uma representação da informação, que através do desenvolvimento de códigos, possibilitam o tratamento dela por máquinas. Nesse sentido, são fragmentos codificados que transcrevem o que determinada informação significa dentro de um sistema computacional, sendo ele inteligente ou tradicional.

Por conseguinte, assim como os dados são símbolos que ordenados traduzem determinada ideia, as informações são conceitos constituídos por diversos dados combinados e que podem auxiliar na geração do conhecimento. "A informação é elemento que compõe o conhecimento. Pode-se dizer, de maneira simplificada, que a informação é o conhecimento possível de se materializar e de ser registrado em algum suporte" (LIMA; ALVARES, 2012, p. 26).

Nesse sentido, de acordo com Zorinho (1995 apud BRAGA, 2000), a informação é um processo que visa o conhecimento, ou melhor, informação é tudo o que reduz a incerteza. Sendo um instrumento de compreensão do mundo e da ação sobre ele.

Em somatório, os conceitos são objetos de estudo de diversas áreas multidisciplinares e possuem variações em suas ideias e abordagens dependendo de onde encontram-se inseridos. Mesmo que dentro de uma mesma área, as concepções variam de acordo com a corrente teórico-epistemológica considerada (DAHLBERG, 1991; POZZI, 1999 apud FRANCELIN; KOBASHI, 2011).

Posições-padrão como o naturalismo e o convencionalismo foram determinantes para que as escolas de pensamento clássicas e modernas construíssem suas teorias em torno da ideia de relação imediata com as coisas da realidade ou em torno da ideia de relação mediata (DAHLBERG, 1991; POZZI, 1999 apud FRANCELIN; KOBASHI, 2011, p. 208).

Em outra obra, no dicionário do livro, o autor apresenta a definição de conceito como pensamento. "Noção selecionada para reter como unidade de análise semântica, para fins de indexação. Na indexação os conceitos existentes num documento são extraídos pela análise, que os exprime através de palavras-chave" (FARIA; PERICÃO, 2008 apud FRANCELIN; KOBASHI, 2011).

Segundo Langridge (2006 apud FRANCELIN; KOBASHI, 2011), a ideia primordial de conceito é distingui-los das palavras. Se os conceitos refletem os conhecimentos das ciências, eles se apresentam por meio de algum signo, a palavra. Porém, o conceito não se limita ao universo da palavra. Ele pode existir independente de uma palavra que o defina.

Nessa perspectiva, conceito é a operação da inteligência na qual se apreendem os caracteres essenciais daquilo que é familiar. É a representação mental do que se sabe, por exemplo: ideia, coisa, julgamento (PIEDEDE, 1983 apud FRANCELIN; KOBASHI, 2011).

Para Langridge (2006 apud FRANCELIN; KOBASHI, 2011), é possível haver um conceito que não seja capaz de ser expresso por uma palavra ou não identificamos uma palavra para usar. Para ela, o conceito não é o mesmo que a palavra.

Do mesmo modo, o conceito, segundo Piedade (1983 apud FRANCELIN; KOBASHI, 2011), deve ser distinguido do assunto. Os assuntos podem ser vistos como conjuntos de conceitos de determinada disciplina. Assim como Langridge, Piedade (1983 apud FRANCELIN; KOBASHI, 2011, p. 210) assegura que o conceito é a "[...] operação da inteligência através da qual se apreendem os caracteres essenciais daquilo que se conhece. É a representação mental do que se sabe, uma ideia, uma coisa, um julgamento".

Dito isso, para Hjørland (2008), a organização da informação, no sentido mais restrito, trata-se de atividades como a descrição, indexação e classificação

documentais realizadas tanto por humanos, quanto por algoritmos de computador. Por outro lado, o sentido mais amplo direciona a perspectiva de outras áreas sobre a organização da informação, onde ela não é um objeto principal de estudo. Ele define o conceito amplo como a divisão social do trabalho mental.

Nas palavras do autor, essa visão ampla é sobre como a organização da informação funciona socialmente, enquanto a restrita ocorre de forma intelectual ou cognitiva. Apesar das diferenças, Hjørland (2008) destaca a importância do sentido amplo para o restritivo, visto que não seria possível o desenvolvimento de um corpo informacional fértil restritivo sem considerar a perspectiva ampla e social.

Ademais, a organização da informação é dividida em dois principais aspectos: processos e sistemas. Primordialmente, os processos relacionam-se à classificação feita por humanos e computadores, processos de catalogação, análise de assunto e indexação. Enquanto os sistemas são focados nos conceitos de natureza semântica, como tesouros, ontologias, metadados, lista de assuntos e sistemas classificatórios. Com os avanços tecnológicos, o meio no qual a maior parte desses processos e sistemas se desenvolvem atualmente é novo, mas os princípios básicos fazem parte da organização da informação (HJØRLAND, 2016).

A Internet e seus mecanismos de busca revolucionaram a forma como as pessoas pesquisam e encontram informações. Em comparação com as bases de dados clássicas que requerem especialistas em informação profissionais ou utilizadores finais competentes em informação, os motores de busca são (ou parecem ser) muito fáceis de utilizar. Além disso, os motores de busca têm uma cobertura ampla e abrangente de muitos tipos de documentos. A Internet tornou-se o meio mais importante para organizar e pesquisar informações e documentos (HJØRLAND, 2016, p. 481).

Para Hjørland (2011 apud Hjørland 2016), indexadores humanos e programadores são guiados por conhecimento e teorias. Nesse sentido, com o papel de ferramentas auxiliaadoras, existem importantes abordagens teóricas dentro e fora do campo da organização da informação a serem consideradas. Inerente a área, as mais relevantes são abordagens: praticista e intuitiva, baseadas em consenso, análises de facetas, cognitivas e baseadas no usuário, analíticas/epistemológicas de domínio. Já de forma externa a área, as abordagens destacadas são: bibliométricas e recuperação da informação (HJØRLAND, 2016).

Segundo Goodfellow, Bengio e Courville (2016), dentro de sistemas inteligentes, a classificação consiste no programa da máquina sendo solicitado a especificar a qual das categorias alguma entrada pertence. Para executar esse processo, o algoritmo produz uma função matemática que permite correspondências numéricas para a análise classificatória das características. A classificação pode ser feita de diferentes formas, como pela entrada descrita por vetor a uma categoria identificada por código numérico e pela distribuição de probabilidade sobre diferentes classes. Destaca-se também a análise de imagem para reconhecimento de objetos. Nesse cenário, a entrada é a imagem e a mesma é descrita pelo valor do brilho do pixel, e a saída é um código numérico que identifica o objeto na imagem.

A classificação possui diversas funções e atende a muitas áreas do conhecimento. No entanto, a comunicação entre estas áreas é marcada por falhas. Consequentemente, o campo da classificação é marcado por reinvenções fragmentadas e de elevado custo. Dito isso, com as inovações ocorrendo de forma exponencial e um volume de informação maior a cada momento, a classificação começou a atrair mais atenção pelo papel de auxiliar usuários a fazerem uso da quantidade crescente de informação que surgia online. Diante disso, a partir da necessidade de classificação de áreas relacionadas a tecnologia, surgiram as ontologias (SOERGEL, 1999).

A estrutura ontológica é fundamental para o desenvolvimento de inteligência de máquina, e da comunidade científica e acadêmica. Ela desempenha diversas funções relacionadas ao pensamento, comunicação, organização e recuperação de informações, tanto por pessoas, quanto por sistemas tecnológicos. Estas funções mencionadas, incluem: fornecer roteiro semântico internamente e externamente a um campo, funcionar como suporte para a recuperação da informação, servir de base conceitual para sistemas de algoritmos e para consideração de hierarquia de objetos, ser um dicionário para seres humanos e para linguagens de processamento, e ser uma estrutura capaz de atender a todas os campos, linguagens e culturas. No entanto, é destacado pelo autor que o termo de ontologia assumiu o conceito de classificação superficial de grupos simples. Conforme as necessidades classificatórias de campos como linguística e inteligência artificial se tornaram mais específicas e menos básicas, houve mais análise e conscientização

sobre aspectos que se encontravam que além de problemas catalográficos, como as terminologias. De forma complementar, as variações entre áreas são explicadas pela falta de troca de informações entre comunidades científicas (SOERGEL,1999).

2.4 GESTÃO DA INFORMAÇÃO

Tendo em vista a influência de inteligências artificiais e dos dados que a permitem gerar informação, é indispensável mencionar o que o desenvolvimento e uso dessa tecnologia representa para a sociedade e empresas. Segundo Braga (2000), a informação é valiosa e importante para todos os grupos. O acesso e uso dela é essencial, ordenada ou não ordenada.

Caminha-se para a sociedade do saber onde o valor da informação tende a suplantar a importância do capital. A informação e o conhecimento são a chave da produtividade e da competitividade. A gestão moderna exige que a tomada de decisão seja feita com o máximo de informação (BRAGA, 2000¹).

De acordo com Reis (1993 apud BRAGA, 2000), é necessário que se estabeleçam um conjunto de políticas coerentes que possibilitem o fornecimento de informação relevante, de boa qualidade, que esteja disposta de forma correta, seja precisa e de fácil acesso, para uma gestão eficaz.

Gerir a informação é, assim, decidir o que fazer com base em informação e decidir o que fazer sobre informação. É ter a capacidade de selecionar um repositório de informação disponível aquela que é relevante para uma determinada decisão e, também, construir a estrutura e o design desse repositório (Zorrinho, 1995 apud BRAGA, 2000²).

Dito isso, além de ser uma moeda atual valiosa e auxiliar no processo de tomada de decisão, como mencionado acima, auxilia a desenvolver uma estrutura organizacional mais consistente. Nesse sentido, as tecnologias da informação são essenciais para a existência de sistemas integrados e completos que estão presentes na maioria das esferas sociais.

¹ O material referenciado não possui paginação.

² O material referenciado não possui paginação.

Segundo Venkatraman, referido por O'Brien (1996), o verdadeiro poder das TI está em "reestruturar as relações nas redes empresariais para aproveitar um leque mais vasto de competências". As TI permitem assim, ultrapassar todo um conjunto de barreiras na medida em que existe uma nova maneira de pensar, pois em tempo real é possível às empresas agir e reagir rapidamente aos clientes, mercados e concorrência (BRAGA, 2000³).

Para complementar, segundo Braga (2000), "na sociedade da informação, esta possui um efeito multiplicador que dinamizará todos os sectores da economia, constituindo, por sua vez, a força motora do desenvolvimento político, económico, social, cultural e tecnológico. O acesso à informação e a capacidade de, a partir desta, extrair e aplicar conhecimentos são vitais para o aumento da capacidade concorrencial e o desenvolvimento das atividades comerciais num mercado sem fronteiras. As vantagens competitivas são agora obtidas através da utilização de redes de comunicação e sistemas informáticos que interconectam empresas, clientes e fornecedores".

Logo, considerando as citações apresentadas, reafirma-se a importância da organização da informação em tecnologias como deep learning. Através da disposição e classificação adequada da informação é possível desenvolver planeamentos, produtos e serviços de forma eficaz que atenda aos interesses e demandas sociais e organizacionais.

³ O material referenciado não possui paginação.

3 PROCEDIMENTOS METODOLÓGICOS

Este estudo tem como objetivos analisar a relação entre Deep Learning e organização da informação, e investigar o uso de dispositivos dessa aplicação. Para tanto, a metodologia aplicada no desenvolvimento deste trabalho é de natureza descritiva e exploratória. Isto posto, além da pesquisa bibliográfica apresentada previamente, foi realizado um levantamento de campo para maior compreensão sobre problemas relacionados ao tema.

A seguir serão indicados o campo de pesquisa, a população e a amostra, e as técnicas de coleta e análise de dados, que foram definidas para explorar a presença, frequentemente onipresente, da organização informacional em aplicações tecnológicas e identificar possíveis problemas em dispositivos Deep Learning. Por conseguinte, contribui para a execução do estudo e análise detalhada dos assuntos da pesquisa.

3.1 CAMPO DA PESQUISA, POPULAÇÃO E AMOSTRA

O universo escolhido para pesquisa em questão foram alunos que estão cursando ou são formados nos cursos de Biblioteconomia e Gestão de Unidades de Informação, ou Ciência da Computação, pela Universidade Federal do Rio de Janeiro.

Nesse sentido, o critério de escolha dos cursos foi a familiaridade dos estudantes, cursando ou formados, com pelo menos um dos temas da relação, organização da informação e inteligência artificial, analisada neste estudo.

De acordo com Hjørland (2008), apesar da organização da informação ter a biblioteconomia como área de estudo principal, ela também é muito explorada pelo campo da ciência da computação. Diante disso, a limitação do grupo possibilitou a compreensão de perguntas específicas sobre os temas presentes no questionário e, consequentemente, contribuiu para maior confiabilidade dos dados coletados. A amostra da pesquisa é não-probabilística e é constituída por 30 participantes, sendo 21 pessoas da área de Biblioteconomia, 8 pessoas de Ciência da Computação e 1 pessoa pertencente às duas áreas.

3.2 TÉCNICAS DE COLETA E ANÁLISE DE DADOS

Primordialmente, os fundamentos teóricos do estudo foram obtidos e agrupados através de pesquisa bibliográfica, que se utilizou da literatura disponível, nos idiomas português e inglês, tais como livros, artigos acadêmicos e revistas especializadas das áreas de Biblioteconomia e Ciência da Computação.

Em seguida, a coleta de dados foi feita através de respostas provenientes de um questionário online, desenvolvido pelo site Google Forms. O questionário possuía 9 perguntas, abertas e fechadas, e o link dele foi disseminado em grupos de ambos os cursos nas redes sociais Facebook e WhatsApp, e enviado de forma privada para alguns dos estudantes sem acesso a esses grupos. Considerando os dados coletados e o formato das perguntas, a análise será qualitativa e quantitativa.

4 RESULTADOS


Esta seção apresenta os resultados provenientes da pesquisa qualitativa e quantitativa. Para a obtenção desses resultados, foi aplicado um questionário online para a população definida, alunos formados ou atuais alunos da graduação dos cursos de Biblioteconomia e Gestão de Unidades de Informação, e Ciência da Computação da Universidade Federal do Rio de Janeiro (UFRJ). A escolha pela população foi definida a partir dos conhecimentos adquiridos ao longo da graduação de ambas as áreas. Nessa perspectiva, os participantes possuem familiaridade com pelo menos um dos temas analisados, o que é essencial para a compreensão das perguntas selecionadas.

O questionário foi composto por 7 questões fechadas, sendo 6 delas obrigatórias e 1 de caráter condicional opcional, e 2 questões abertas opcionais. A divulgação do formulário foi feita por meio de Redes Sociais, como Facebook e WhatsApp, e direcionada somente ao atual e antigo corpo discente dos cursos em questão. Estabelecido que a abordagem seria não probabilística, o questionário foi respondido por 30 integrantes da população.

Em vista disso, as questões iniciais possuíam o objetivo de definir a área de conhecimento e compreender a abrangência do domínio dos participantes sobre os temas especificados. Primeiramente, identificando qual das duas graduações já haviam cursado ou estavam cursando no momento da aplicação da pesquisa.

A pergunta foi "Qual é a sua área de estudo?" e as opções de respostas eram: Biblioteconomia e Gestão de Unidades de Informação, ou/e Ciência da Computação.

GRÁFICO 1 – CURSO DA GRADUAÇÃO




Fonte: Dados da pesquisa (2022)

A partir do gráfico 1, nota-se que a maior participação quantitativa no questionário é advinda de atuais ou antigos alunos do curso de Biblioteconomia e Gestão de Unidades de Informação, sendo 21 pessoas (70%). Enquanto a amostra da área de Ciência da Computação é formada por 8 respondentes (26,7%). Ademais, não se limitando à formação única em uma das áreas previamente citadas, 1 pessoa participante (3,3%) possui formação em ambas as áreas, sejam concluídas ou em andamento.

Possibilitando uma análise mais aprofundada dos perfis individuais traçados e considerando as múltiplas plataformas educacionais atuais que não se enquadram em ensino superior, a segunda pergunta é em relação ao domínio dos tópicos essenciais para definição da profundidade e da orientação da relação entre o respondente e o tema do estudo.

A pergunta foi "Como você definiria seu conhecimento na área de informação e tecnologia?" e as opções de respostas eram: domínio sobre fundamentos da organização da informação, domínio sobre programação e domínio sobre ambos.

GRÁFICO 2 – ÁREAS DE DOMÍNIO DE CONHECIMENTO



Fonte: Dados da pesquisa (2022)


De acordo com o gráfico 2, 70% da amostra (21 pessoas) considera possuir conhecimentos sobre organização da informação, que é fundamental para maior entendimento do fluxo informacional que é descrito no estudo. De forma complementar, 13,3% (4 pessoas) afirma ter domínio sobre o campo da programação, parte integrante do processamento e da técnica da aplicação de inteligência analisada de forma teórica na pesquisa. Além disso, no âmbito multidisciplinar, 16,7% (5 pessoas) possuem noções teóricas nas duas áreas, organização da informação e programação.

Em sequência, é avaliada a percepção individual da presença da ordenação de dados e informações na rotina, objetivando coletar dados sobre a consciência dos

respondentes sobre a frequência do uso de dispositivos e de serviços em atividades recorrentes.

A pergunta foi "O quão presente é a ordenação de dados e informações em sua rotina?" e a opção de resposta era em formato de escala gradativa de 1 a 4, sendo 1 ausente e 4 muito presente.

GRÁFICO 3 – ORDENAÇÃO DE DADOS E INFORMAÇÕES NA ROTINA



Fonte: Dados da pesquisa (2022)

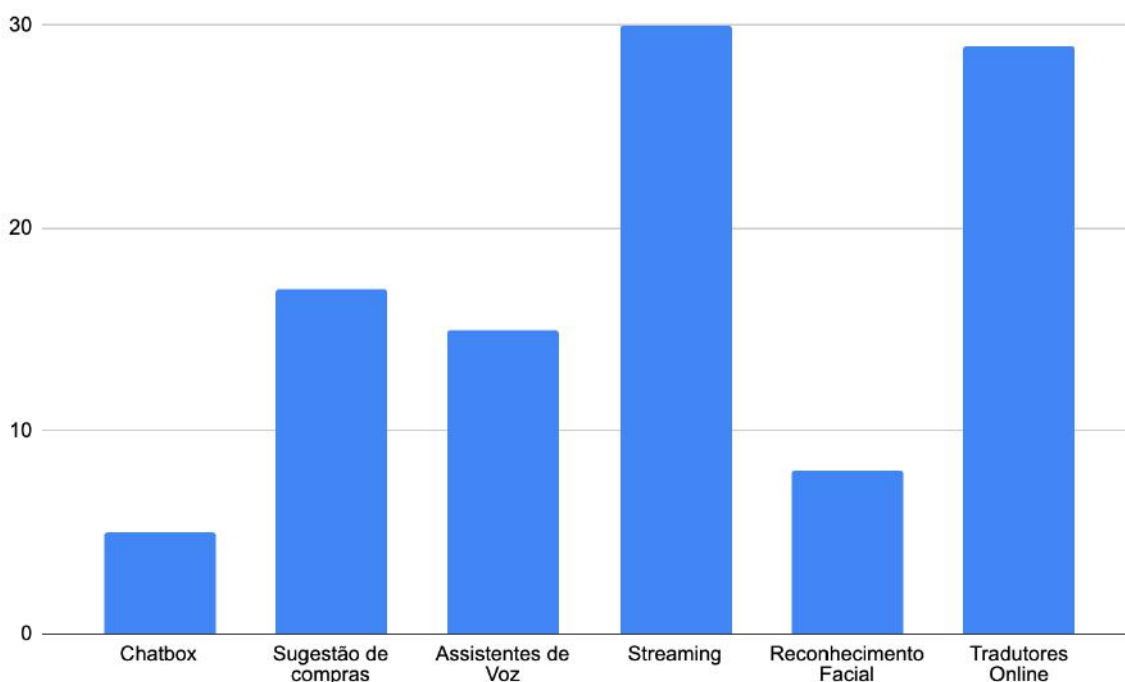
Como pode ser observado no gráfico 3, a predominância das respostas está concentrada no grau 3, que abrange 53,3% da amostra (16 pessoas). Em outras palavras, mais da metade dos respondentes identificam a ordenação de dados e informações como um fator presente nas atividades de rotina, porém não consideram essa presença muito forte. Simultaneamente, 5 pessoas se consideram mais distantes dessa ordenação, tendo 2 pessoas (6,7%) optado pela opção 1, indicador de total ausência, e 3 pessoas (10%) optado pelo grau 2, que representa a pouca presença.

Finalizando a análise do gráfico, encontra-se no grau 4 o segundo maior grupo, composto por 9 pessoas (30%). O grau mais elevado representa a forte existência da organização de dados e informações nas atividades do dia a dia.

Já na pergunta que sucede a análise, o objetivo é identificar quais serviços e dispositivos de Deep Learning são usados pelos participantes. As opções "Não uso nenhum dispositivo ou serviço" e "Outra opção" não foram marcadas na amostra, obtendo assim a porcentagem 0%. Por esse motivo, ambas não se encontram no gráfico.

A pergunta foi "Você utiliza dispositivos ou aplicações inteligentes?" e as opções de respostas eram: não uso, recomendações em sites de compras online, assistentes de voz (Siri, Google, Alexa), serviços de streaming (Spotify, Globoplay, Netflix, Prime Video, Twitch, HBO Max), chatbox, reconhecimento facial (Apple, Google, Facebook), tradutores online (Google Translate, Microsoft Translator, Reverso) e uma lacuna para preenchimento em caso de outra opção.

GRÁFICO 4 – USO DE SERVIÇOS E DISPOSITIVOS



Fonte: Dados da pesquisa (2022)

Como é possível observar no gráfico 4, os participantes poderiam selecionar mais de uma opção, considerando que as inovações tecnológicas estão cada vez mais presentes em diversos setores e funções básicas da vivência social, profissional e educacional. Nesse sentido, há unanimidade de 100% (30 pessoas) na utilização de serviços de streaming, como Twitch, Spotify, Globoplay, Netflix e outros. Seguindo a ordem de escolhas, os tradutores online, como Google Translate, são usados por 96,7% da amostra (29 pessoas).

Com 56,7% dos indivíduos (17 pessoas), as sugestões de compras online presentes em diversos websites aumentam cada vez mais. De forma simultânea, as empresas possuem maior liberdade para usar de dados e informações de usuários, o que aumenta a compatibilidade entre o que é sugerido no anúncio e o perfil de consumidor de cada indivíduo.


Na perspectiva de reconhecimento sonoro e gráfico, as assistentes de voz, como Siri e Alexa, foram selecionadas por 50% dos participantes (15 pessoas). Enquanto isso, aplicações de reconhecimento facial obtiveram 26,7% (8 pessoas).

Concluindo com 16,7% das respostas, 5 pessoas selecionaram o chatbox, programa simulador de diálogo humano que é, constantemente, usado em atendimento ao cliente.

Conectando-se à questão anteriormente analisada, os dados coletados apresentados no gráfico a seguir foram obtidos através de uma questão condicionada ao uso de mais de um serviço ou dispositivo. O objetivo foi compreender se há fluxo direto de informação pessoal entre as tecnologias utilizadas por um mesmo indivíduo.

A pergunta opcional foi "Se você tem mais de um dispositivo ou serviço inteligente, eles estão sincronizados um com o outro?" e as opções de respostas eram: sim, parcialmente e não.

GRÁFICO 5 – SINCRONIZAÇÃO DOS SERVIÇOS E DISPOSITIVOS



Fonte: Dados da pesquisa (2022)


A pergunta condicional, representada no gráfico 5, foi respondida por aproximadamente 28 pessoas, ou seja, 93% do total de respondentes da pesquisa. Considerando o grupo de 28 respostas a totalidade (100%) da questão em específico, o maior índice foi na opção "parcialmente sincronizados", escolhida por 13 pessoas (46,43%). Então, a maioria define que conecta seus dispositivos em partes limitadas ou não conecta todos entre si, apenas alguns.

Simultaneamente, 9 participantes (32,14%) afirmam que não acopla os dados e informações de um dispositivo ou serviço com outros. Finalizando a porção da amostra, 6 pessoas (21,43%) conectam em sua totalidade os dispositivos ou serviços usados.

De forma complementar, a questão a seguir questiona se os participantes entendem como funciona o fluxo de informação em dispositivos de Deep Learning, objetivando a análise da familiaridade com a dinâmica operacional dessa aplicação que possibilita a execução da ação com que o usuário interage.

A pergunta foi "Você entende a dinâmica do fluxo informacional presente na aplicação inteligente Deep Learning?" e as opções de respostas eram: sim ou não.

GRÁFICO 6 – COMPREENSÃO DA DINÂMICA DO FLUXO
INFORMACIONAL EM DEEP LEARNING



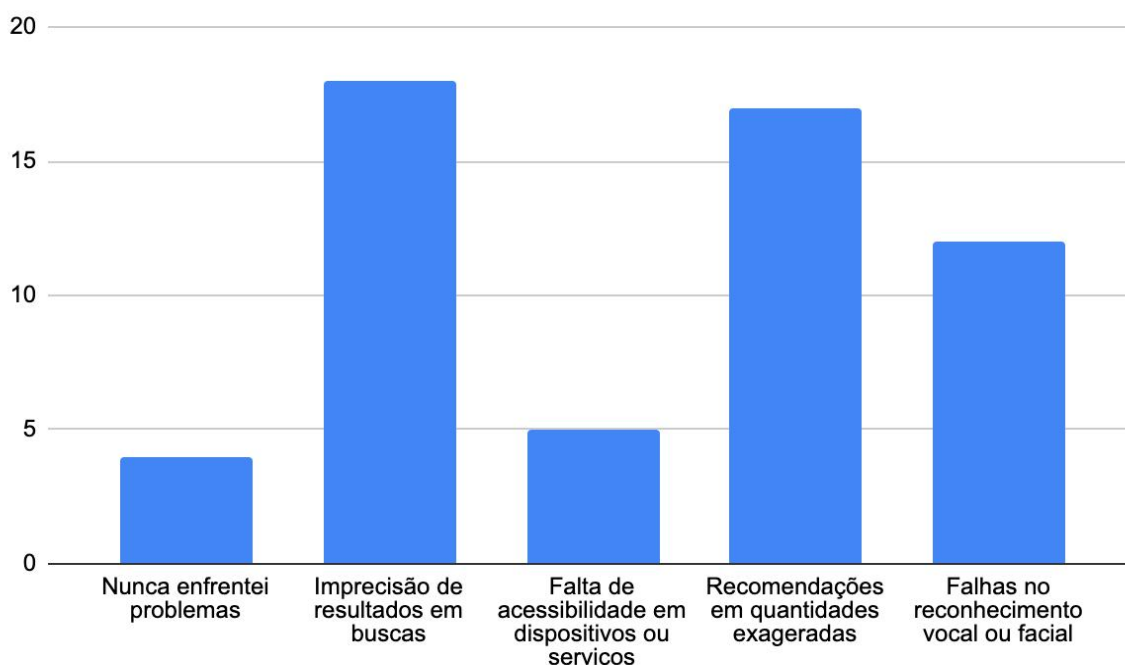
Fonte: Dados da pesquisa (2022)

Conforme o gráfico 6 apresenta, 70% dos participantes (21 pessoas) afirma que não entende sobre o processamento de aplicações inteligentes que possibilita a entrega ao usuário da informação esperada como produto. Enquanto isso, em sentido oposto, 30% (9 pessoas) entende o que são as redes neurais, responsáveis pela funcionalidade do Deep Learning, e como elas interagem.

Ademais, em seguida os discentes são questionados sobre problemas que enfrentam com o uso das aplicações que são citadas previamente no gráfico 4, como streaming e tradutores. A questão possuía a marcação de "Outra opção" e lacuna disponível para preenchimento de problemas não citados. Todavia, esta alternativa não foi escolhida dentro da amostra (0%). Por esse motivo, não se encontra no gráfico.

A pergunta foi "Você enfrenta algum desses problemas com esses dispositivos ou serviços?" e as opções de respostas eram: nunca enfrentei problemas, falha de reconhecimento vocal ou facial, recomendações em quantidades exageradas, falta de acessibilidade de dispositivos ou serviços, imprecisão de resultados em buscas e uma lacuna para preenchimento em caso de outra opção.

GRÁFICO 7 – PROBLEMAS COM O USO DE SERVIÇOS OU DISPOSITIVOS



Fonte: Dados da pesquisa (2022)

Como pode ser observado acima, a avaliação do questionamento proposto no formulário e representado no gráfico 7 é essencial para identificar e compreender os problemas que os integrantes da amostra percebem durante o uso de mecanismos de Deep Learning.

Apesar de 4 indivíduos (13,3%) afirmarem que nunca enfrentaram problemas com a utilização da tecnologia estudada na pesquisa, a maior parte da amostra se posiciona em sentido contrário. Entre as adversidades enfrentadas durante uso,

destaca-se a imprecisão de resultados em buscas realizadas pelo usuário, que foi selecionada por 18 pessoas (60%), e recomendações exacerbadas baseadas no perfil individual e histórico de consumo, opção apontada por 17 pessoas (56,7%).

Finalizando a análise dos dados que compõem o gráfico em questão, as falhas no reconhecimento vocal e facial receberam 12 votos (40%). Ademais, a falta de acessibilidade é marcada por 5 pessoas (16,7%) como um obstáculo durante o uso.

Possuindo caráter opcional e aberto, as duas questões finais que completam o questionário (apêndice A) indagam os participantes em relação a uma solução, ou mais, para os problemas apontados durante a pesquisa.

Sendo a penúltima pergunta direcionada a uma perspectiva e reflexão individual: o que o respondente faria para solucionar o problema. Já na questão final que considera o cenário de decisões e burocracias empresariais: como o respondente acredita que as empresas poderiam solucionar os problemas indicados previamente em Deep Learning.

No âmbito individual, um dos participantes salienta a importância da possibilidade do cadastro com máscara em aplicações de reconhecimento facial e sugere o mesmo como uma solução, visto que, em tempos de pandemia, torna-se inviável e perigoso a utilização sem máscara do reconhecimento facial em dispositivos portáteis nas ruas. Outros mencionam como soluções: contatar o atendimento ao cliente ou suporte por e-mail, reiniciar o dispositivo ou aplicativo, bloquear anúncios através do navegador, e falar pausadamente com assistentes de voz.

Já na perspectiva empresarial, apontam como estratégias interessantes para solucionar problemas: melhoria de análise de dados para resultados mais precisos, limitação equilibrada de recomendações para maior satisfação do usuário e melhoria de sistemas.

5 CONCLUSÃO

Com base nas referências bibliográficas e na coleta de dados obtidas no questionário respondido por discentes do curso de Biblioteconomia e Gestão de Unidades de Informação, e Ciência da computação da Universidade Federal do Rio de Janeiro (UFRJ), a pesquisa, por meio de dados, mostra-se academicamente colaborativa para maior compreensão de fundamentos teóricos sobre os tópicos e a correlação, ainda pouco explorada, entre as áreas estudadas. Ademais, através dos dados obtidos pela aplicação do questionário, torna-se possível propor soluções para problemas presentes em aplicações deep learning que podem contribuir para melhorar a experiência dos usuários.

A princípio, através da leitura das referências apresentadas, torna-se perceptível a proximidade entre conceitos de processos e sistemas da organização da informação e o funcionamento de aplicações deep learning, principalmente a classificação de informações. Esta classificação acontece por meio das camadas de redes neurais, que também realizam o processamento e análise de dados, e é um dos fatores que contribuem para aproximar a máquina de um raciocínio cognitivo.

Nesse sentido, a dinâmica de uma aplicação Deep learning funciona de forma em que dados preenchem a etapa inicial, depois são analisados por diferentes camadas das redes neurais para que sejam encontrados aspectos representativos neles que permitam a classificação, e, conseqüentemente, reproduza o resultado esperado pelo sistema. De forma complementar, o modelo backpropagation assume o papel de treinar efetivamente esses sistemas e aprimorá-los com base em métodos matemáticos obtidos de partes pertencentes à estrutura, que objetivam a acurácia da informação gerada no fim do processo.

Dito isso, os processos e sistemas de informação estão diretamente ligados ao desempenho de máquinas inteligentes. Por conseguinte, caso ocorram ruídos nessa relação, poderia haver incômodos ou prejuízos ao usuário que detém o dispositivo.

O estudo apresentou e analisou arquiteturas de redes neurais básicas e populares em sistemas de baixa e média complexidade. Então, no questionário aplicado foram analisados dados sobre aplicações que estão constantemente

presentes na rotina. Nas respostas, destaca-se que em uma das questões 70% dos participantes indicam falta de entendimento sobre fluxos informacionais em estruturas deep learning e em outra pergunta 86,7% deles indicaram algum tipo de contratempo com dispositivos que usam. Imprecisão de resultados de buscas, recomendações exageradas e falha no reconhecimento foram os mais apontados pelos participantes.

Para solucionar as problemáticas apresentadas no questionário por atuais e antigos discentes, propõe-se a possibilidade de cadastro de rostos com máscaras para que sistemas consigam corresponder a imagem ao usuário, e o desenvolvimento de sistemas e dispositivos com a opção de restringir a classificação de características gerais e comuns, a fim de que recomendações e resultados não se tornem uma poluição informacional que não atenderá as demandas dos usuários.

Em outro sentido, seguindo a observação de Lin (2020), apresentada no estudo anteriormente, sobre possíveis riscos no uso de deep learning no campo da internet das coisas e em cenários de maior complexidade, alguns modelos de redes neurais apresentam grandes falhas em seu funcionamento quando analisados no campo de internet das coisas. Além de ser um obstáculo desafiador, tipos de problemas como esse podem colocar a segurança do usuário em posição frágil.

Em suma, a pesquisa conclui que aplicações inteligentes são guiadas por informação e dados em estruturas funcionais arquitetadas para explorar com maior aproveitamento essa relação. No entanto, de forma oposta, as áreas de tecnologia e biblioteconomia apresentam pouca interação acadêmica e científica entre si. Por fim, a aproximação colaborativa entre os campos mostra-se um fator importante para contribuição na resolução de problemas e desenvolvimento de inovações relacionadas a modelos multidisciplinares.

REFERÊNCIAS

BRAGA, Ascensão. A Gestão da Informação. **Millenium**, [s. l.], n. 19, Jun. 2000. Disponível em: <https://repositorio.ipv.pt/handle/10400.19/903>. Acesso em: 10 ago. 2021.

ČOLAKOVIĆ, Alem; HADŽIALIĆ, Mesud. Internet of Things (IoT): a review of enabling technologies, challenges, and open research issues. **Computer Networks**, [s. l.], v. 144, p. 17-39, 24 out. 2018. Disponível em: <https://www.sciencedirect.com/science/article/abs/pii/S1389128618305243>. Acesso em: 22 set. 2021.

FRANCELIN, M. M.; KOBASHI, N. Y. Concepções sobre o conceito na organização da informação e do conhecimento. **Ciência da Informação**, [s. l.], v. 40, n. 2, 2012. Disponível em: <http://revista.ibict.br/ciinf/article/view/1311>. Acesso em: 7 jun. 2021.

GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. **Deep Learning**. [s. l.]: The MIT Press, 2016.

HJØRLAND, Birger. Knowledge Organization (KO). **Knowledge Organization**, [s. l.], n. 6, ed. 43, p. 475-484, 2016. Disponível em: <https://www.nomos-elibrary.de/10.5771/0943-7444-2016-6-475.pdf>. Acesso em: 27 jan. 2022.

HJØRLAND, Birger. What is Knowledge Organization (KO)? **Knowledge Organization**, [s. l.], v. 35, ed. 2-3, p. 86-101, 2008. Disponível em: <https://www.nomos-elibrary.de/10.5771/0943-7444-2008-2-3-86/what-is-knowledge-organization-ko-volume-35-2008-issue-2-3?page=1>. Acesso em: 4 jan. 2022.

JESTE, Dilip *et al.* Beyond artificial intelligence: exploring artificial wisdom. **International Psychogeriatrics**, [s. l.], v. 32, ed. 8, 25 jun. 2020. Disponível em: <https://www.cambridge.org/core/journals/international-psychogeriatrics/article/beyond-artificial-intelligence-exploring-artificial-wisdom/AEFF76E8D643E2B7210995E3ABDAA722>. Acesso em: 9 ago. 2021.

LECUN, Yann; BENGIO, Yoshua; HINTON, Geoffrey. Deep Learning. **Nature**, [s. l.], v. 521(7553), p. 436-444, 28 maio 2015. DOI 10.1038/NATURE14539. Disponível em: <https://www.nature.com/articles/nature14539>. Acesso em: 10 maio 2021.

LIMA, José; ALVARES, Lilian. Organização e representação da informação e do conhecimento. In: LIMA, José. **Organização da informação e do conhecimento: conceitos, subsídios interdisciplinares e aplicações**. [s. l.]: B4 Editores, 2012. cap. 1, p. 21-33. Disponível em: https://www.researchgate.net/publication/281969932_Organizacao_e_representacao_da_informacao_e_do_conhecimento. Acesso em: 4 ago. 2021.

LIN, Tao. Deep Learning for IoT. In: IEEE INTERNATIONAL PERFORMANCE COMPUTING AND COMMUNICATIONS CONFERENCE, 39., 2020, Austin. **Anais eletrônicos** [...] Austin: IEEE, 2021. p. 1-4. Disponível em:

<https://ieeexplore.ieee.org/abstract/document/9391558>. Acesso em: 13 fev. 2022.

M'NG, Jacinta Chan Phooi; MEHRALIZADEH, Mohammadali. Forecasting East Asian Indices Futures via a Novel Hybrid of Wavelet-PCA Denoising and Artificial Neural Network Models. **Plos one**, [s. l.], v. 11. ed. 6, p. 1-29, 2016. Disponível em: https://www.researchgate.net/publication/303744090_Forecasting_East_Asian_Indices_Futures_via_a_Novel_Hybrid_of_Wavelet-PCA_Denoising_and_Artificial_Neural_Network_Models. Acesso em: 13 fev. 2022.

SAARIKKO, Ted; WESTERGREN, Ulrika; BLOMQUIST, Tomas. The Internet of Things: are you ready for what's coming?. **Business Horizons**, [s. l.], v. 60, ed. 5, p. 667-676, setembro/out. 2017. Disponível em: <https://www.sciencedirect.ez29.periodicos.capes.gov.br/science/article/pii/S000768131730068X?via%3Dihub>. Acesso em: 12 maio 2021.

SAOERGER, Dagobert. The rise of ontologies or the reinvention of classification. **Journal of the American Society for Information Science**, [s. l.], v. 50, ed. 12, p. 1119-1120, 1999. Disponível em: https://scholar.google.com.br/citations?view_op=view_citation&hl=pt-BR&user=4bJ6HcUAAAAJ&citation_for_view=4bJ6HcUAAAAJ:zYLM7Y9cAGgC. Acesso em: 9 fev. 2022.

SCHMIDHUBER, Jürgen. Deep learning in neural networks: An overview. **Neural Networks**, [s. l.], v. 61, p. 85-117, Jan. 2015. Disponível em: <https://www.sciencedirect.com/science/article/abs/pii/S0893608014002135>. Acesso em: 13 set. 2021.

APÊNDICE A – MODELO DO QUESTIONÁRIO

1. Qual é a sua área de estudo?

☐ Biblioteconomia e Gestão de Unidades de Informação

☐ Ciência da Computação

2. Como você definiria seu conhecimento na área de informação e tecnologia?

☐ Domínio sobre fundamentos da organização da informação

☐ Domínio sobre programação

☐ Domínio sobre ambos

3. O quão presente é a ordenação de dados e informações em sua rotina?

Resposta em escala gradativa de 1 a 4, sendo 1 ausente e 4 muito presente.

4. Você utiliza dispositivos ou aplicações inteligentes?

☐ Não uso

☐ Recomendações em sites de compras online

☐ Assistentes de voz (Siri, Google, Alexa, entre outros)

☐ Serviços de streaming (Spotify, Globoplay, Netflix, Prime Video, Twitch, HBO Max, entre outros)

☐ Chatbox

☐ Reconhecimento facial (Apple, Google, Facebook, entre outros)

☐ Tradutores online (Google Translate, Microsoft Translator, Reverso, entre outros)

☐ Outros _____

5. Se você tem mais de um dispositivo ou serviço inteligente, eles estão sincronizados um com o outro? (Opcional)

☐ Sim

☐ Parcialmente

☐ Não

6. Você entende a dinâmica do fluxo informacional presente na aplicação inteligente Deep Learning?

☐ Sim

☐ Não.

7. Você enfrenta algum desses problemas com esses dispositivos ou serviços?

☐ Nunca enfrentei problemas

☐ Falha de reconhecimento vocal ou facial

☐ Recomendações em quantidades exageradas

☐ Falta de acessibilidade de dispositivos ou serviços

☐ Imprecisão de resultados em buscas

☐ Outros _____

8. Como você resolveria esse(s) problema(s)? (Opcional)

9. Como você acredita que a empresa responsável poderia resolver esse problema? (Opcional)
